Propuesta de Automatización e Inteligencia Artificial

Soluciones Inteligentes y Escalabilidad Operativa

Dirigido a: Mostaza y Pan
Presentado por: Servicio de Automatización DNX
Fecha: 18 may 2025



Documentación Técnica y Propuesta Financiera: Servicio de Automatización DNX

1. Justificación y Propuesta de Valor

Contratar personal informático adicional implica costos fijos elevados, tiempos de inducción, licencias laborales, horas no cubiertas (guardias de noche o fines de semana) y la ejecución constante de tareas repetitivas de Nivel 1 (restablecimiento de claves, consultas de precios, verificación de estado de incidentes e ingesta manual de documentos).

El Agente de IA DNX opera **24/7/365**, respondiendo al instante tanto a clientes externos (consultas comerciales y tótem) como a colaboradores internos (soporte técnico, resolución de dudas e ingesta de documentación), garantizando una reducción sustancial del costo operativo y un nivel de escalabilidad ilimitado.

2. Descripción de la Arquitectura del Sistema

(Nota: El esquema gráfico vectorial ejecutable de la arquitectura se mantiene y gestiona por separado en el Anexo de Diagramación / Draw.io para facilitar la actualización independiente de los workflows).

- ### Componentes Clave de la Arquitectura
  - **Control de Acceso y Whitelist:** La consulta en BD de registros valida el `telegram_id` del solicitante y verifica su rol asignado (*Técnico* vs *Usuario*) antes de enrutar la solicitud.
  - **Patrón Manager-Worker:**
    - **Manager (AI Agent + Switch):** Clasifica la intención del usuario en categorías operativas (Tótem, Precios, General).
    - **Workers:** Invoca sub-workflows especializados (`Call Asistente de Totem`, `Call Asistente Totem Verificador de Articulos Precios`) mediante la ejecución directa de `executeWorkflow`.
  - **Correlación de traceId y Gestión de Memoria:**
    - La sesión se correlaciona de forma unívoca a través de la clave `chat.id` / `sessionKey`.

    - **Memoria Inmediata:** Administrada dinámicamente mediante `memoryBufferWindow`.
    - **Memoria a Corto Plazo / Low Memory:** El historial reciente de interacciones se almacena en `AgentMemory`. Cuando el historial supera los límites de tamaño establecidos (5 ítems), un proceso automatizado (agente estructurado) resume la conversación, la almacena en `LowAgentMemory` y depura registros antiguos para optimizar el contexto y minimizar el consumo de tokens.
- **Módulo RAG e Ingesta Documental:** Conexión con *Vector Store* (Ollama) gestionado mediante evaluación previa de score técnico.

3. Modelo de Datos y Estructura de Tablas del Sistema

Para soportar la trazabilidad, gestión de fallos y aprendizaje continuo, la solución se integra con cuatro tablas principales:

A. Tabla `incidencias`

Registra consultas operativas o casos donde la información provista debía ser precisa pero, por alguna inconsistencia de datos o del sistema (ej. un artículo que no figura en un sistema local), requiere seguimiento técnico. El agente consulta y actualiza esta tabla dinámicamente mediante herramientas especializadas (DataTableTools).

- **Esquema:**
    - `titulo` (string): Categoría del incidente (ej. "Error de Precios").
    - `detalle` (string): Descripción técnica enviada por el usuario (ej. "no aparece 600 en MAC").
    - `resolucion` (string): Explicación del ajuste o solución aplicada.
    - `estado` (string): Ciclo de vida del ticket (`Ingresado`, `En proceso`, `Solucionado`, `Rechazado`).

B. Tabla `mejoras`

Módulo de recolección de oportunidades de mejora ubicado al cierre de cada flujo/circuito de interacción. Cuando la respuesta brindada no satisface completamente la consulta o se clasifica fuera del alcance automatizado, la interacción se registra en esta tabla para ser analizada como un nuevo requerimiento de entrenamiento del modelo.

- **Esquema:**

    - `mensaje` (string): Texto completo enviando el contexto o la consulta que no pudo ser resuelta automáticamente.
    - `chat` (string): Identificador único de Telegram/Chat del contacto.

C. Tabla `errors`

Tabla de fallos de infraestructura y ejecución del flujo. Si algún agente o worker falla (`onError`), se guarda el registro y se envía una notificación Gmail automática al administrador.

- **Esquema:**
    - `detalle` (string): Traza técnica del error o mensaje capturado en el worker.
    - `contacto` (string): ID y nombre del usuario afectado.

D. Tabla `Contactos`

Directorio de usuarios y técnicos autorizados para el control de acceso.

- **Esquema:**
    - `number` (string): Número o identificador del usuario.
    - `name` (string): Nombre y apellido del contacto registrado.

4. Gobernanza, Auditoría y Control de Calidad

Para garantizar que el agente no devuelva respuestas ambiguas ni incurra en alucinaciones, la arquitectura implementa una capa estricta de supervisión automática e intervención humana (*Human-in-the-Loop*).

A. Mecanismo del Supervisor de Ingesta (Human-in-the-Loop)

- **Ingesta de Documentación:** Cuando se sube un documento técnico o manual (vía Webhook o PDF), este no ingresa inmediatamente a la base de conocimiento de producción.
- **Evaluador Automático (AI Agent2):** Analiza el documento con un analizador estructurado que asigna una puntuación (*score* de 0 a 10) y determina si el contenido es relevante e inteligible (`is_useful`).
- **Umbrales Configurables:**
    - **Score $\ge$ 7:** Documento calificado como apto. Se indexa automáticamente en la base vectorial (*Vector Store*) utilizando *Ollama Embeddings*.

- **Score < 7:** Se activa el flujo *Human-in-the-Loop* vía Telegram. Un supervisor humano recibe la justificación del rechazo junto con el archivo original, permitiendo aprobar o rechazar manualmente la incorporación mediante botones dinámicos.

B. Auditoría y Fallback de Errores

- **Métricas y Logs:** Toda interacción, flujo de decisión y tiempo de respuesta se registra detalladamente en tablas de auditoría (Airtable / Data Tables).
- **Manejo de Excepciones:** Si algún agente presenta una falla (`onError: continueErrorOutput`), la excepción se cataloga en la tabla de errores y desencadena inmediatamente una alerta crítica por correo electrónico (nodo Gmail) dirigida al equipo de infraestructura.

5. Análisis Financiero y ROI (Return on Investment)

Para dimensionar el impacto operativo, analicemos el comportamiento financiero según el volumen mensual de consultas atendidas.

A. Escenario Base: 400 Consultas Mensuales

Un volumen de 400 consultas representa la carga típica de trabajo manual de primer y segundo nivel que absorbería un técnico informático a tiempo completo.

Concepto	Técnico Informático (Nivel 1/2)	Servicio Agente AI DNX
Volumen de Atención	~400 - 500 consultas / mes	Ilimitado (24/7)
Costo Operativo Mensual	~$1,200.00 USD / mes	~$50.00 USD / mes (APIs + Servidor)
Costo por Consulta Atendida	~$3.00 USD / consulta	~$0.125 USD / consulta
Disponibilidad Horaria	8 horas/día (40hs/semana)	24 horas / 7 días a la semana
Carga Operativa Evitada	N/A	120 - 160 horas humanas/mes

- **Costo Anual Manual:** $14,400 USD/año

- **Costo Anual DNX:** $600 USD/año
- **Ahorro Neto Anual: $13,800 USD/año** (Reducción del **95.8%** en gasto directo)

B. Escenario de Escalabilidad: 1,000 Consultas Mensuales

Al alcanzar **1,000 consultas mensuales**, la operación manual sobrepasa la capacidad de un solo técnico en jornada normal (requiriendo 2 personas o el pago de guardias y horas extra). El servicio automatizado DNX absorbe esta demanda incrementando marginalmente solo el consumo de APIs.

Concepto	Operación Manual (2 Técnicos N1/N2)	Servicio Agente AI DNX
Volumen de Atención	1,000 consultas / mes	1,000 consultas / mes (24/7)
Costo Operativo Mensual	~$2,400.00 USD / mes	~$90.00 USD / mes (APIs + Servidor)
Costo por Consulta Atendida	~$2.40 USD / consulta	**~$0.090 USD / consulta**
Disponibilidad Horaria	Limitada a turnos rotativos	24 horas / 7 días a la semana
Carga Operativa Evitada	N/A	**300 - 400 horas humanas/mes**

- **Costo Anual Manual (2 Técnicos):** $28,800 USD/año
- **Costo Anual DNX (1,000 consultas/mes):** $1,080 USD/año ($90 USD/mes)
- **Ahorro Neto Anual: $27,720 USD/año** (Reducción del **96.25%** en gasto operativo)

Conclusión Financiera y Eficiencia de Escala

A mayor volumen de consultas, el costo unitario por interacción del servicio DNX disminuye (de **$0.125 USD** a **$0.090 USD** por consulta), demostrando una alta eficiencia de escala frente a la contratación tradicional de personal, el cual escala con costos fijos rígidos e incrementales.

6. Próximos Pasos de Despliegue

Al estar la arquitectura probada de forma modular dentro del flujo base de n8n, el despliegue e implementación en el entorno de producción requiere la siguiente hoja de ruta:

1. **Fase 1:** Conectar la base vectorial de producción (*Vector Store* / Ollama) con los manuales y bases de datos actualizadas de la organización.
2. **Fase 2:** Asignar los roles y permisos correspondientes en la tabla de usuarios (*whitelist*) para canalizar consultas técnicas e internas de forma segura.
3. **Fase 3 (opcional):** Robot autónomo capaz de atender gente que no puede hacer el pedido vía autoservicio (disponible campaña de marketing), vía TTS para hablar con los clientes, una pantalla por si el cliente no escucha y hacer muestra de los productos de los que está hablando



Repositorio: https://github.com/dnx1994/coder/
Documento Directiva: https://github.com/dnx1994/coder/blob/main/Propuesta%20Comercial%20Ejecutiva%20-%20Servicio%20de%20Automatizaci%C3%B3n%20DNX%20(Mostaza%20y%20Pan)%20-%20Documentos%20de%20Google.pdf